

СОБЕСЕДОВАНИЕ · MACHINE LEARNING

Machine Learning Interview

Avito



Разбор реальных вопросов с собеседования: классический ML, ансамбли, Computer Vision, NLP и продвинутые темы — с готовыми ответами и тегами по темам.

26

ЗАДАЧ С ОТВЕТАМИ

5

тем: ML-база, ансамбли, CV, NLP, DL

НАВИГАЦИЯ

Кому и зачем этот файл

Для тех, кто готовится к техническому собеседованию на позицию в data science / ML в Avito или на похожую позицию в другой компании. Это гайд по подготовке к ML-собесу — с вопросами, которые реально задают на секции. Пять разделов: классический ML, ансамбли, Computer Vision, NLP и DL. У каждого вопроса — тег по теме (bert, boosting, NLP и т.д.) и уровень сложности от DS2 до DS4. По каждому — не просто правильный ответ, а как его объяснить: закрыть пробелы, сверить формулировки и научиться говорить идею, а не кидаться терминами. Собрано по воспоминаниям тех, кто эти собесы проходил, и по реальным материалам для интервьюеров Avito — так что формулировки максимально близки к тому, что звучит на настоящей секции.

Идите подряд по разделам или сразу открывайте нужный по оглавлению. Перед своим собеседованием быстро пройдитесь по тегам вашего направления — так проще найти релевантные вопросы.

Содержание

Основы ML	8 задач	стр. 3
Ансамбли	5 задач	стр. 8
Computer Vision	3 задачи	стр. 11
NLP	8 задач	стр. 14
Продвинутые темы	2 задачи	стр. 17

#ML-БАЗА

Основы ML

Линейная регрессия, регуляризация, метрики качества, градиентный спуск.

8 задач

1 Регуляризация

DS2

regularization

base

Что такое регуляризация? Расскажи какие виды регуляризации для линейных моделей ты знаешь.

Регуляризация это способ борьбы с переобучением, для линейных моделей есть L1, L2 (а также их комбинация — Elastic Net, L1 + L2). В регуляризации для линейных моделей мы добавляем норму весов или квадрат нормы весов к оптимизационному функционалу.

Почему добавление нормы весов помогает бороться с переобучением?

Потому что симптом переобучения — это очень большие веса. Если веса очень большие, то возможна ситуация, что будут два одинаковых объекта, но один признак у них будет отличаться на эпсилон, а целевое значение будет отличаться очень сильно — эта ситуация нездоровая.

2 Линейная регрессия

DS2

base

Рассмотрим задачу линейной регрессии со среднеквадратичной ошибкой. В этом случае получаем задачу оптимизации:

$$(1/\ell) \cdot |Xw - y| \rightarrow \min \text{ по } w$$

Если продифференцировать данный функционал по вектору w , приравнять к нулю и решить уравнение, то получим явную формулу для решения:

$$w = (XX^T)^{-1}X^Ty$$

Почему на практике не решают задачу линейной регрессии через вычисления по явной формуле для весов?

- Обращение матрицы — сложная операция.
- Матрица X^TX может быть вырожденной или плохо обусловленной. В этом случае обращение либо невозможно, либо может привести к неустойчивым результатам. Проблема решается с помощью регуляризации.

Какая сложность обращения матрицы?

Сложность стандартного алгоритма обращения матрицы кубическая — этого уже достаточно для ответа. Плюсом будет упомянуть алгоритм Штрассена за $O(n^{2.81})$, а

есть и быстрее, но там ограничения на матрицы.

Как тогда решают задачу линейной регрессии?

Обычно используют градиентные методы оптимизации: GD, SGD.

3 Регуляризация


DS3

regularization

base

Почему L1 разреживает, а L2 нет?

Например, можно обосновать так. Рассмотрим пример, когда у нас два веса w_1 и w_2 . Рассмотрим график, по осям отложим веса w_1 и w_2 :



L1-регуляризация — это ромб на левом графике. Линии уровня оптимизационного функционала $Q = \|Xw - y\|^2$ — это вытянутые эллипсы. Оптимум находится в точке касания линий уровня и ромба, вероятность, что это произойдёт в углу ромба, значительно выше, чем на стороне ромба.

Пояснение про точку касания. В точке минимума $Q(w) + \alpha R(w)$ выполняется условие $\partial Q / \partial w_i + \alpha \cdot \partial R / \partial w_i = 0$, что означает, что градиенты $\partial Q / \partial w_i$ и $\partial R / \partial w_i$ коллинеарны, а линии уровня касаются. Хотя для L1 функционал $R(w)$ недифференцируемый на осях, его углы можно сгладить.

Альтернативное объяснение. В покомпонентном градиентном спуске легко видеть, что в случае L2-регуляризации $|\partial R / \partial w_i|$ уменьшается по мере приближения к нулю, и в какой-то момент в градиенте полной функции потерь станет доминировать $\partial Q / \partial w_i$. В случае L1-регуляризации $|\partial R / \partial w_i| = 1$, и градиентный спуск будет стремиться дойти до нуля.

Нужно ли включать вес w_0 в регуляризатор?

Нет, не нужно. Включая вес w_0 в регуляризатор, мы не будем давать модели смещаться гиперплоскости в нужную часть, где лежат данные. Качество в большинстве случаев станет только хуже.

4 Метрики качества. Precision Recall

DS4

metrics

base

Метрики качества. Задача на понимание precision и recall

Решаем модерационную задачу: необходимо находить контакты в тексте описания объявления. Есть фиксированные ресурсы ручной модерации, часть потока можем отправлять им на дополнительную проверку. Нужно построить модель и подобрать два порога:

- порог для автоотклонения объявления,
- порог для отправки на проверку в ручную модерацию.

Что важнее при выборе порога в двух случаях: точность построенной модели или полнота?

Ответ

- При выборе порога для автодействий важнее точность, так как автоотклонять лишнего нельзя — пользователи завалят поддержку (могут писать гневные посты на пикабу).
- При выборе порога для ручной модерации нужно смотреть на полноту при максимальном потоке, который способны обработать люди.

5 Метрики качества

DS2

auc_roc

metrics

base

Что такое AUC-ROC?

Можно объяснить, что это доля верно упорядоченных пар, можно через площадь под кривой.

Ты решаешь задачу регрессии, ты знаешь, что у тебя в выборке встречаются выбросы. Какую метрику ты предпочтёшь оптимизировать: MAE или MSE?

Лучше MAE, так как MSE более чувствительна к выбросам. Плюсом будет ещё упомянуть Huber loss :) Из недостатков MAE стоит знать — нет производной в нуле, из-за этого дольше обучается.

Что такое точность, полнота, доля правильных ответов?

Тут формулы достаточно или объяснения на пальцах.

6 Метрики качества. AUC-ROC

DS3

auc_roc

metrics

base

Метрики качества. Задача на понимание AUC-ROC

Вы решали задачу бинарной классификации и получили AUC-ROC 0.92. Как изменится AUC-ROC 0.92, если в выборке продублировать каждый объект положительного класса 7 раз, а каждый объект отрицательного класса 4 раза?

Ответ

AUC-ROC не изменится. Тут любое разумное объяснение подойдет. Проще всего расписать AUC-ROC как долю верно упорядоченных пар — тогда коэффициенты числителя и знаменателя сократятся.

7 Метрики качества. AUC-ROC

DS4

auc_roc

metrics

base

Метрики качества. Задача на понимание AUC-ROC

Ты решаешь задачу поиска контактов в описании объявления (задача бинарной классификации). Ты обучил классификатор и получил ROC-AUC > 0.99.

Ты внедряешь свою модель в продакшн и решаешь посылать на ручную модерацию объекты, которые получили максимальную вероятность от твоей модели. Тебе можно послать на ручную модерацию 1000 объектов в день. Всего модель скорит 1 млн объявлений в день. Возможна ли такая ситуация, что среди 1000 отправленных моделью объектов не было ни одного объекта класса +1?

Ответ

Да, возможно. Если выборка несбалансированная, например всего 1 тыс. положительных объектов на 999 тыс. отрицательных, а модель отсортировала объекты в следующем порядке: 990 тыс. отрицательных, 1 тыс. положительных, 9 тыс. отрицательных объектов — тогда ROC-AUC > 0.99.

8 Градиентный спуск

DS3

base

Какие модификации градиентного спуска известны?


Модификации градиентного спуска, например, AdaGrad (RMSProp), SGD + momentum, Adam, Adan.

Что такое SGD + momentum и зачем он нужен?

Аккумулируем градиенты с последних шагов, во многих ситуациях увеличивается скорость сходимости.

Приведите пример линий уровня функций, при которых momentum будет сходиться значительно быстрее обычного SGD

Вытянутые линии уровня, как на картинке, потому что градиент перпендикулярен линиям уровня.



#АНСАМБЛИ

Ансамбли

Беггинг, случайный лес, градиентный бустинг, гиперпараметры GBDT.

5 задач

9 Ансамбли алгоритмов. Беггинг

DS2

ensembles

bagging

base

Что такое беггинг?

Беггинг — это bootstrap aggregation. Выбираем бутстрапированную выборку (семплируем объекты с возвращением), на каждой бутстрапированной выборке обучаем алгоритм и усредняем ответы алгоритмов.

Что будет, если сделать беггинг над линейными алгоритмами?

Получим линейный алгоритм. Сумма гиперплоскостей — это гиперплоскость.

10 Ансамбли алгоритмов. Беггинг

DS3

ensembles

bagging

base

Как устроен RandomForest?

Это беггинг над решающими деревьями + метод случайных подпространств по признакам. В момент построения дерева в каждой вершине дерева выбирается случайное подмножество признаков, и лучшее разбиение выбирается только среди этого подмножества.

Очень важно, что случайное подмножество выбирается в каждой вершине дерева заново, а не один раз на всё дерево — это частая ошибка в ответе. Если признаковое пространство большое, то деревья получаются довольно глубокие, и это может сильно замедлить скорость инференса.

Почему подмножество на всё дерево — это ошибка: пусть есть небольшой процент супер информативных признаков, а остальные признаки вносят вклад, но не очень существенный — тогда деревья, которым не достался ни один информативный признак, будут иметь очень низкое качество, и при усреднении они испортят весь беггинг.

Как беггинг влияет на смещение и дисперсию предсказаний?

Смещение не меняется, а дисперсия уменьшается. В идеале дисперсия уменьшается в N раз, где N — это число алгоритмов, но это если ответы алгоритмов не скоррелированы между собой, что на практике не так.

Задача на понимание беггинга и бустинга

Допустим, мы обучили две композиции решающих деревьев: случайный лес и градиентный бустинг. В обоих случаях мы остановили добавление деревьев, когда ошибка на валидационной выборке перестала убывать. Что произойдёт с ошибкой этих моделей на валидационной выборке, если мы продолжим обучение и добавим в каждую из них по 10000 деревьев?

Ответ

Для беггинга качество не изменится, в бустинге качество упадёт.

11 Ансамбли алгоритмов. Бустинг

DS2

ensembles

boosting

base

Что такое градиентный бустинг?

Это сумма базовых алгоритмов (обычно деревьев), алгоритмы учатся последовательно, каждый базовый алгоритм учится исправлять ошибки предыдущих. Целевая переменная в каждом базовом алгоритме — это антиградиент функции потерь в точке суммы предыдущих алгоритмов.

Какие реализации градиентного бустинга ты знаешь?

CatBoost, LightGBM, XGBoost. Можно ещё поговорить про особенности реализаций — например, какие деревья строят в CatBoost (oblivious tree) и LightGBM (leaf-wise).

Что такое стекинг/блендинг?

Стекинг — обучаем мета-модель поверх предсказаний нескольких базовых моделей (обычно на отдельном фолде/выборке, чтобы не переобучиться на утечке).

Блендинг — упрощённый вариант: мета-модель обучается на предсказаниях базовых моделей на отложенной выборке, без кросс-валидации.

12 Ансамбли алгоритмов

DS4

ensembles

bagging

boosting

base

Почему на inference в промышленной среде (если нам важна скорость ответа алгоритма) часто лучше отдавать предпочтение GBDT, а не RF?

В RF рекомендуется строить деревья, которые имеют небольшое смещение и большой разброс, чтобы при беггинге уменьшить разброс. Поэтому рекомендуют не ограничивать глубину деревьев. Если признаковое пространство большое, то деревья получаются довольно глубокие, и это может сильно замедлить скорость инференса.

В бустинге рекомендуется использовать неглубокие деревья, и часто можно добиться сравнимого или даже лучшего качества, чем у RF, при этом ускорив инференс.

Здесь может напрашиваться довод про параллельный обсчёт деревьев в RF. Но, во-первых, на inference точно так же можно параллелить GBDT. Во-вторых, стоит держать

в голове: будет ли выигрыш от распараллеливания, когда нужно отдавать предсказание на одном примере за раз? В реальности распараллеливание в этом случае приведёт к уменьшению скорости работы из-за overhead от запуска нескольких тредов на каждый пример.

13 Гиперпараметры в GBDT

DS3

ensembles

base

Какие гиперпараметры в GBDT стоит подбирать в первую очередь?

В качестве ответа стоит назвать хотя бы следующие: глубина дерева или число листьев в нём, learning rate, минимальное число примеров в листе, коэффициенты регуляризации (см. ниже).

Используется ли в GBDT L1- и L2-регуляризация? Что выполняет роль весов в ней?

Да, используется. В роли весов выступают значения в листьях деревьев.

Как можно подбирать значения гиперпараметров?

Ищем значения, минимизирующие ошибку на отложенной выборке или в кросс-валидации. Тестируемые значения гиперпараметров выбираем с помощью поиска по сетке (в простых случаях), случайного сэмплирования или через байесовские алгоритмы оптимизации. Последние используются в optuna и hyperopt.

Дополнительно стоит быть готовым рассказать, в каких случаях не подходит перебор по сетке и почему (когда нужно подбирать больше пары-тройки гиперпараметров — из-за проклятия размерности), а также как работают байесовские алгоритмы оптимизации.

#COMPUTER VISION

Computer Vision

Свёрточные сети, Inception, Residual block, практика на Kaggle.

3 задачи

14 CV. CNN

DS2

CV

Что такое свёрточный слой нейронной сети?

Основной блок свёрточной нейронной сети. Слой свёртки включает в себя для каждого канала свой фильтр, ядро свёртки которого обрабатывает предыдущий слой по фрагментам (суммируя результаты поэлементного произведения для каждого фрагмента).

Что такое pooling слой?

Пулинговый слой призван снижать размерность изображения. Исходное изображение делится на блоки размером $w \times h$, и для каждого блока вычисляется некоторая функция. Чаще всего используется функция максимума (max pooling) или (взвешенного) среднего (average pooling). Обучаемых параметров у этого слоя нет.

Основные цели пулингового слоя:


- уменьшение изображения, чтобы последующие свёртки оперировали над большей областью исходного изображения;
- увеличение инвариантности выхода сети по отношению к малому переносу входа;
- ускорение вычислений.

Что такое Inception module?

Inception module — это специальный слой нейронной сети, был предложен в работе, в которой была представлена сеть GoogLeNet. Основная цель этого модуля заключается в следующем.

Авторы предположили, что каждый элемент предыдущего слоя соответствует определённой области исходного изображения. Каждая свёртка по таким элементам будет увеличивать область исходного изображения, пока элементы на последних слоях не будут соответствовать всему изображению целиком.

Однако, если с какого-то момента все свёртки станут размером 1×1 , то не найдётся элементов, которые покрывали бы всё исходное изображение, поэтому было бы невозможно находить крупные признаки. Чтобы решить эту проблему, авторы предложили так называемый inception module — конкатенацию выходов для свёрток размера 1×1 , 3×3 , 5×5 , а также операции max pooling'a с ядром 3×3 .




К сожалению, подобный наивный подход (naive inception module) приводит к резкому увеличению числа слоёв, что не позволяет построить с его использованием глубокую нейронную сеть. Поэтому авторы предложили использовать модифицированный inception module с дополнительным уменьшением размерности — дополнительно к каждому фильтру они добавили слой свёртки 1×1 , который схлопывает все слои изображения в один. Это позволяет сохранить малое число слоёв с сохранением полезной информации об изображении.

Что такое Residual block?

Двумя серьёзными проблемами в обучении глубоких нейронных сетей являются исчезающий градиент (vanishing gradient) и взрывающийся градиент (exploding gradient). Они возникают из-за того, что при дифференцировании по цепному правилу

до глубоких слоёв нейронной сети доходит очень маленькая величина градиента (из-за многократного домножения на небольшие величины на предыдущих слоях).

Для борьбы с этой проблемой был предложен так называемый residual block. Идея заключается в том, чтобы взять пару слоёв (например, свёрточных) и добавить дополнительную связь, которая проходит мимо этих слоёв.



15 CV

DS3

CV

Задача

Вы решаете задачу картиночной классификации на Kaggle. Вы уже обучили CNN. Как, не переобучая её, выжать максимальный скор?

Ответ

- Делать рандомные кропы изображения и усреднить выход по ним.
- В некоторых задачах можно применить модель к повёрнутым на 90 градусов изображениям или к изображениям с изменённым контрастом.

16 CV. Что читал

DS4

CV

Расскажи последнюю статью по CV, которую прочитал. Можно не самую последнюю, но интересную. Как давно читал эту статью?

Заранее загуглите точное название статьи и когда она вышла. Расскажите её содержание своими словами и довольно подробно — так, чтобы было понятно человеку, который её не читал.

#NLP

NLP

Эмбединги, трансформер, BERT, обучение на больших батчах.

8 задач

17 NLP. Embeddings

DS2

NLP

NLP. Embeddings. Какие способы построения эмбедингов слов и текстов ты знаешь?

Bag of words, TF-IDF, word2vec, GloVe, FastText, ELMo, BERT. В ответе стоит вкратце раскрыть идею каждого названного метода — например, как обучается word2vec и в чём его отличие от FastText.


18 NLP. Encoder Decoder

DS3

NLP

transformer

NLP. Encoder Decoder. Расскажи про отличие блоков encoder и decoder в трансформере.



19 NLP. Self Attention

DS3

NLP

bert

transformer

Как работает self-attention?

В ответе важно объяснить идею, зачем это нужно; плюсом будет рассказать про векторы ключ/запрос/значение, а если ещё и формулу написать — совсем отлично.

В чём особенность self-attention в трансформере?

Применяется треугольная маска, чтобы в декодере self-attention не смотрел в будущее.

20 NLP. Positional Encoding

DS2

NLP

bert

transformer

NLP. Positional Encoding. Что такое positional encoding?

К вектору слова добавляем закодированную позицию слова. Идея в том, чтобы эмбединги одного и того же токена на разных позициях чем-то отличались. Есть статьи, в которых говорят, что positional encoding не нужен. Плюсом будет рассказать про различные модификации, например RoPE (rotary positional embeddings).

NLP. Positional Embeddings. Задача. Изменятся ли эмбединги токенов для BERT, если переставить слова в предложении?

Да, из-за позиционного эмбединга.

21 NLP. Bert Embedding

DS3

NLP

bert

NLP. Эмбединг из BERT. Как, пользуясь обученным BERT, можно получить эмбединг для текста целиком?

Ответ

Из необучаемых способов можно взять пулинг всех токенов (avg, max), эмбединг от CLS-токена. Также можно обучить эмбединг под свою задачу — скажем, если нужно оценивать похожесть предложений по смыслу, то можно, как в архитектуре SentenceBERT, к эмбедингам BERT приделать пулинг и Feed Forward слой, а дальше сделать metric learning (siamese или triplet loss), чтобы эмбединги похожих предложений были близки.

22 NLP. Rare word

DS3

NLP

bert

NLP. Rare word. Допустим, в предложении есть редкое слово, например «подкрадули». Сможет ли предобученный BERT дать разумный эмбединг для такого слова?

Ответ

Да. Во-первых, wordpiece разобьёт это слово на несколько токенов, которые часто встречаются. Во-вторых, он учтёт контекст. Дальше можно взять max или avg pooling от нескольких токенов.

23 NLP. Bert QA

DS3

NLP

bert

NLP. BERT на Question Answering. Как обучить BERT на Question Answering?

Семпл представляет собой вопрос (короткий текст) и референсный текст, из которого нужно найти фрагмент, отвечающий на данный вопрос (это может быть статья в вики).

Ответ

Это 2 числа — начало и конец фрагмента с ответом. Решение — как это решается в оригинальной статье BERT: навешиваем на каждый токен 2 Feed Forward слоя, один предсказывает вероятность, что в этом токене начало фрагмента, а другой — что это конец. Дальше в качестве ответа берём аргмаксимумы вероятностей начала и конца.

24 NLP. Batch Size

DS3

NLP

Вы хотите сделать `batch_size = 2048`, но у вас хватает памяти только на 32. Как можно поступить?

Накопление (аккумуляция) градиентов: делаем `loss.backward()` каждый шаг, а `optimizer.zero_grad()` и `optimizer.step()` делаем раз в $2048 / 32$ шага.

#ПРОДВИНУТЫЕ ТЕМЫ

Продвинутые темы

Регуляризация нейросетей и кейс с неупорядоченным множеством.

2 задачи


25 Регуляризация

DS2

DL

Какие способы регуляризации нейронных сетей ты знаешь?

В качестве ответа стоит назвать как минимум batchnorm и dropout. При этом есть множество способов совместно нормализовывать разные группы весов (картинка из arXiv:1803.08494):



В CV иногда используется L2-регуляризация.

Как работает dropout на инференсе?

На инференсе нейроны не выкидываются, функцию активации умножают на $1-p$, где p — это вероятность выкинуть нейрон. Иногда вместо этого на обучении функцию активации домножают на $1/(1-p)$, а при применении исключают слой dropout.

26 Неупорядоченное множество

DS3

DL

Вопрос

Недобросовестные продавцы пытаются создавать несколько аккаунтов и постить с них похожие объявления, чтобы забить собою поисковую выдачу. Это плохой опыт для покупателей, и такие продавцы обходят монетизацию, поэтому платформа борется с подобным поведением.

Для данного аккаунта можно найти похожие с ним по технической информации — например, тех, кто заходил с того же IP. Хотя это и не точные связи, кажется, что по построенному таким образом окружению можно судить, насколько хорошим является аккаунт.

Можешь поразмышлять, какая архитектура нейросети подошла бы для классификации аккаунта на основании его окружения?

Ответ

В ответе — Graph Attention Networks (GAT), Deep Sets или размышления про обычный attention. Важно уметь объяснить, как нейросеть справляется с произвольным числом элементов и почему она нечувствительна к их порядку.

Альтернативным решением может быть искать наиболее похожий аккаунт среди окружения и обучать нейронку на этой паре. Стоит быть готовым ответить, что делать, если есть много аккаунтов, которые похожи на проверяемый, но не очень сильно — выглядит всё равно подозрительно.

[ГОТОВЬСЯ С ЭКСПЕРТАМИ](#)

Хочешь научиться проходить ML-секции?

Мы в ПОСТУПАШКАХ готовим к собеседованиям на ML-инженеров и ML-продактов — от базы до сложных дизайн-секций на senior-грейды. Выбирай курс под свой уровень.

ML СТАРТ

Если вы только заходите в ML — начните с базы: классический ML, метрики, первый пайплайн, работа с данными. Соберёте фундамент, чтобы уверенно проходить первые собеседования.

[Смотреть курс ML СТАРТ →](#)

ML ПРО

Если база уже есть и нужно углубиться — продвинутые темы, ML System Design, разбор сложных задач и подготовка к жёстким дизайн-секциям на senior-грейды.

[Смотреть курс ML ПРО →](#)

Остались вопросы?

Поможем выбрать направление и ответим на всё — просто напишите нашему менеджеру. И подписывайтесь на канал, чтобы не пропускать разборы и задачи.

[Написать менеджеру · @menshe_treh](#)[Подписаться на канал · @postypashki_old](#)